

Proyecto final — Sistema RAG sobre cámaras y fotografía

Dominio y tamaño del corpus

El sistema responde preguntas sobre cámaras y fotografía usando solo la evidencia de cinco documentos: Sensor de imagen, Cámara fotográfica, Objetivo fotográfico, Exposición (fotografía) e Historia de la fotografía, todos de Wikipedia en español. El corpus suma cerca de 14,300 palabras, que se indexaron en 61 chunks.

Dominio	Cámaras y fotografía: sensores, tipos de cámara, óptica, exposición e historia
Documentos	5 artículos de Wikipedia en español ($\approx$ 14,300 palabras en total)
Chunks indexados	61 (300 palabras, solape de 60)
Modelo de embeddings	gemini-embedding-001 (Google AI)
Generación	Gemini (gemini-3.8-flash, con modelos de respaldo)

Cómo se particionó el texto y por qué

Cada documento se divide en ventanas de 300 palabras con un solape de 60 (paso de 240). Con 300 palabras cada chunk conserva contexto suficiente para que su embedding represente un tema y para que Gemini pueda apoyarse en él, pero es lo bastante corto para que la recuperación sea específica: con los 4 chunks por defecto se envían unas 1,200 palabras de evidencia, no documentos completos. El solape del 20 % evita que una idea quede cortada justo en la frontera entre dos chunks, porque lo que cae a caballo aparece completo en al menos uno; el costo es algo de texto duplicado en el índice. Los fragmentos de ruido propios de Wikipedia (listas de enlaces, "Véase también") se indexan igual, y se le indica a Gemini que los ignore.

Cómo decide el sistema abstenerse


Se mide un umbral de similitud con $\text{MIN_SCORE} = 0.65$ el cual se calibró con preguntas reales: las que sí están en el corpus obtuvieron entre 0.72 y 0.76, y las ajenas entre 0.53 y 0.58 (Sony A7IV: 0.584; paella: 0.530), de modo que 0.65 queda en medio con margen. Si ningún chunk lo alcanza, la API se abstiene sin llamar a Gemini y también solo los chunks que superan el umbral llegan a Gemini, y se le exige responder exactamente `NO_EVIDENCE` si no contienen la respuesta. El umbral solo no basta pues una pregunta de cámaras sobre un dato ausente se parece más al corpus que una de cocina, por eso el modelo hace de segundo filtro. Al abstenerse, la respuesta lo dice explícitamente y no se rellena con conocimiento propio del modelo.

Qué hace Google AI y qué hace Chroma


Google AI cumple dos funciones distintas con modelos distintos. Como embeddings (gemini-embedding-001), convierte cada chunk y cada pregunta en un vector; es el mismo modelo en ambos casos, porque si se mezclaran la búsqueda no tendría sentido. Como generación, Gemini redacta la respuesta en español solo con los chunks numerados, citando [n]. ChromaDB no genera nada ni calcula embeddings: recibe los vectores ya calculados, los guarda junto con el texto y los metadatos (archivo y posición) en disco, y dado el vector de la pregunta devuelve los k más cercanos por coseno. FastAPI orquesta el flujo y Streamlit es un cliente HTTP de la API; el índice persiste entre reinicios. Para tolerar la cuota gratuita y la saturación de Gemini, la generación prueba una lista de modelos en orden.

Evidencias


Streamlit



FastAPI



Pregunta fuera del corpus



FastAPI Endpoints

